



**FACULTAD  
DE INGENIERIA**

Universidad de Buenos Aires

**Carrera de especialización  
en Inteligencia Artificial**

# Inteligencia Artificial Embebida

## Trabajo Práctico Integrador



Autor: Torti, Maximiliano

Docentes: Carrique, Juan Esteban  
Gerard, Matías  
Giovanini, Leonardo


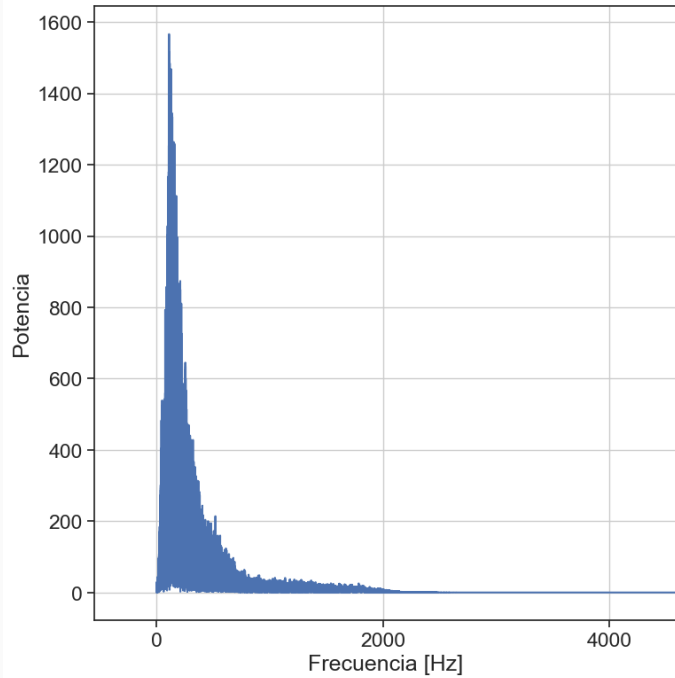
# Consignas

- 1- Crear un modelo capaz de identificar eventos. Utilizar señales de audio de duración variable, donde los eventos masticatorios (chew, bite y chewbite) con marcas temporales
- 2- Crear un modelo capaz de clasificar los eventos. Utilizar señales de audio individuales, etiquetadas como “chew”, “bite” y “chewbite”
- 3- Crear un modelo capaz de determinar la actividad alimentaria utilizando los modelos anteriores y un audio de larga duración que posee las actividades alimentarias etiquetadas.
- 4- Aplicar los modelos anteriores sobre una señal de audio “cruda”.



# Visualización de señales involucradas



# Análisis de señales





# Modelos iniciales detector de eventos



**Accuracy = 0.86**



# Modelos iniciales detector de eventos



**Accuracy = 0.93**

**Dice = 0.55**

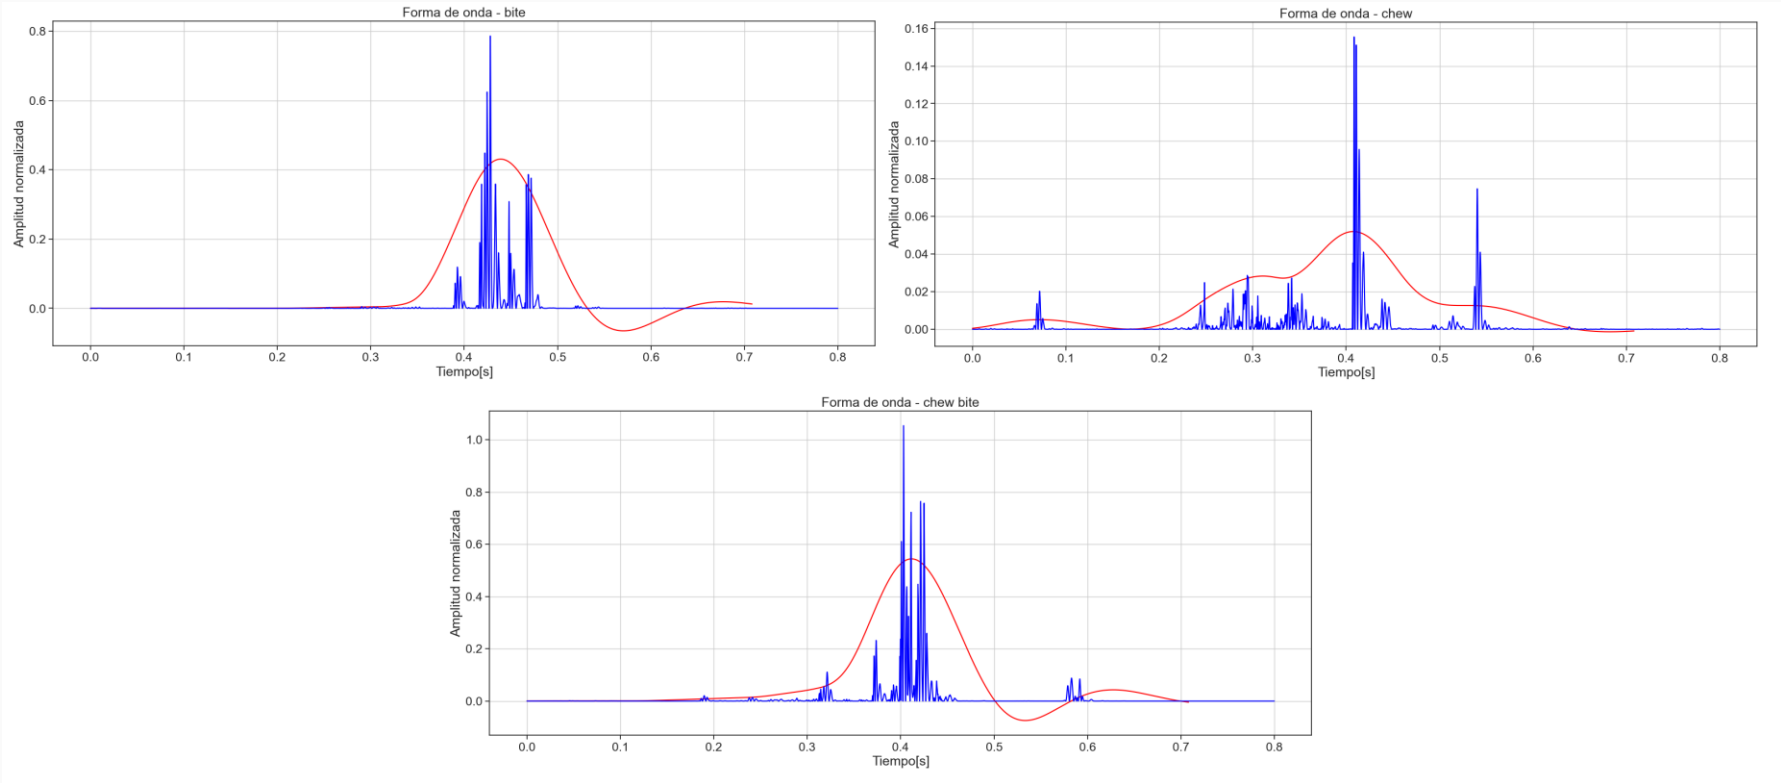
# Modelo final detector de eventos



**Accuracy = 0.88**


**Dice = 0.77**

# Modelo clasificador de eventos - Señales






# Modelo clasificador de eventos - Dataset

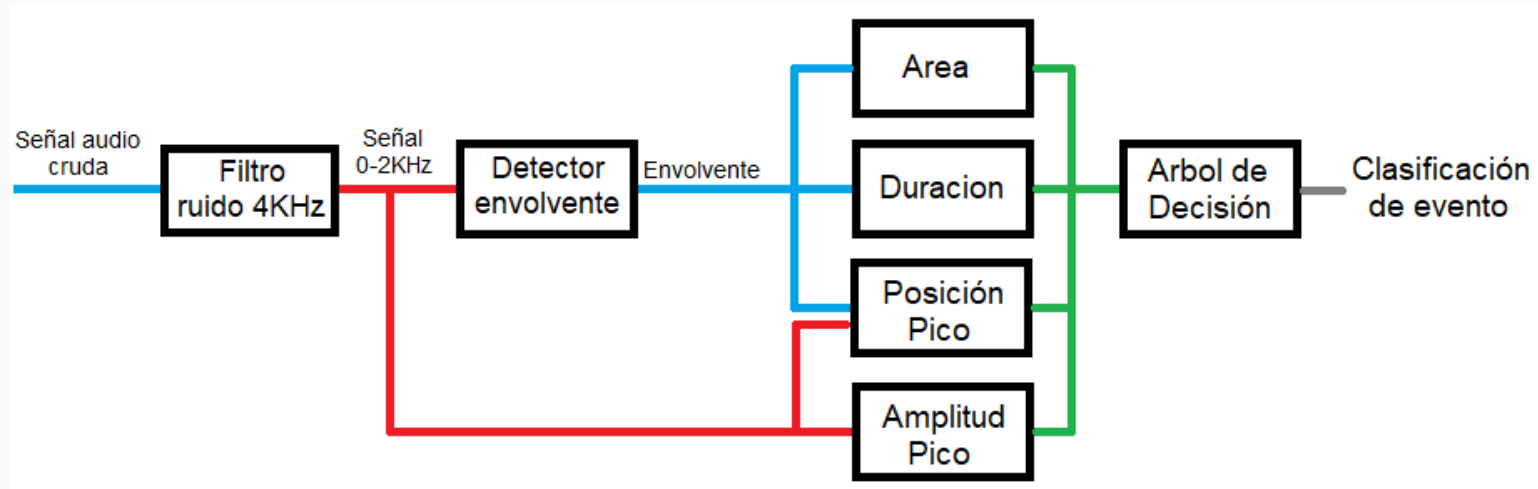


**Dataset desbalanceado**




**Dataset balanceado con undersampling**


# Modelo clasificador de eventos



# Modelo clasificador de eventos



**Train**



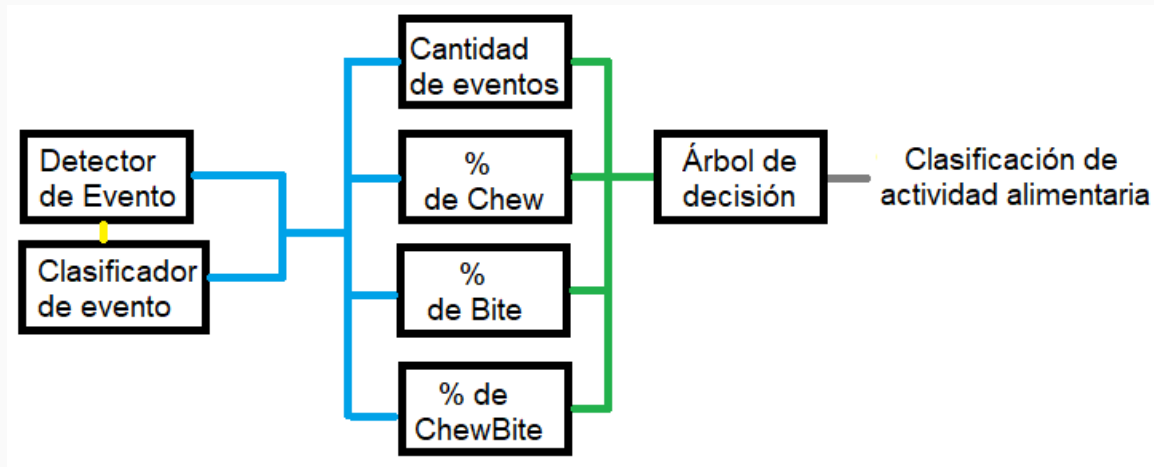

**Test**

# Modelo clasificador de eventos

Clase	recording_01.wav		recording_51.wav		recording_52.wav	
	Accuracy	Dice	Accuracy	Dice	Accuracy	Dice
bite	0.111	0.133	0.622	0.554	0.52	0.165
chew	0.887	0.685	0.8	0.578	0.827	0.675
chewbite	0.514	0.161	0.652	0.344	0.571	0.276

No es conveniente tratar la detección y clasificación de eventos en forma separada y es necesario mejorar el modelo de clasificación.

# Modelo clasificador de actividad alimentaria


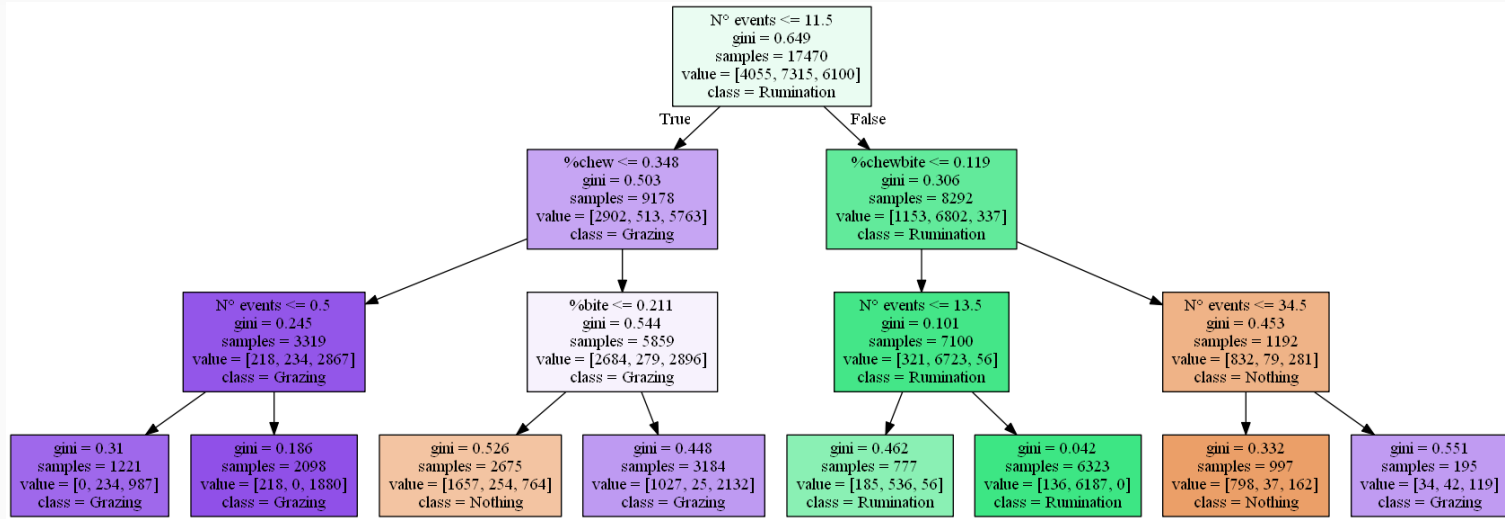


# Modelo clasificador de actividad alimentaria

Clase	Entrenamiento		Testeo	
	Accuracy	F1-Score	Accuracy	F1-Score
Nothing	0.907	0.785	0.91	0.794
Rumination	0.97	0.964	0.969	0.963
Grazing	0.905	0.871	0.906	0.873

Muy buena performance a pesar de que los resultados obtenidos con los modelos de detección y clasificación de eventos eran regulares.

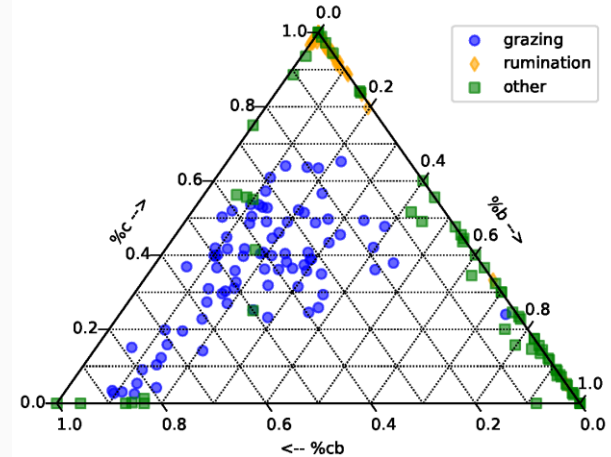
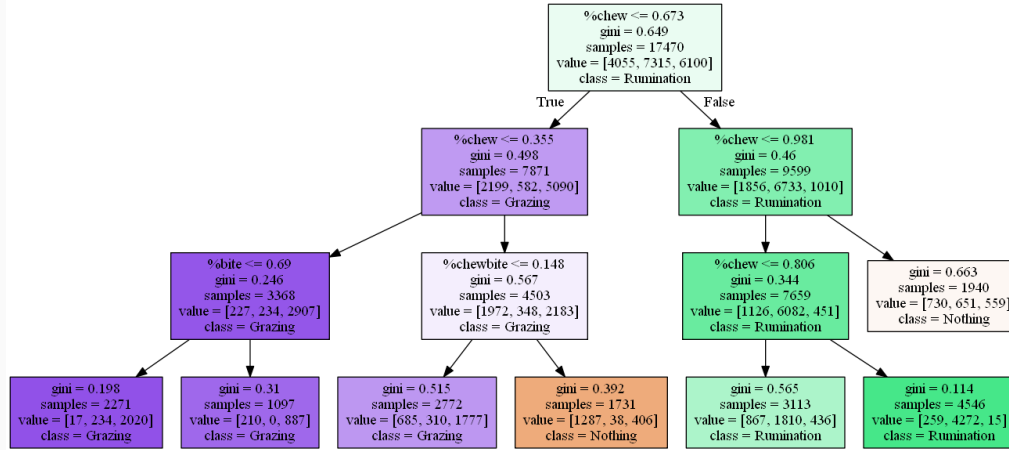
# Comparativa con CBIA



Las reglas de decisión no coinciden, en especial para Rumination.

Para mejor comparación, se entrena nuevamente quitando el feature N° de eventos

# Comparativa con CBIA



Nuevamente las reglas de decisión no coinciden. Podría decirse que se aproximan para Grazing pero no para los otros eventos (coherente con el hecho que el modelo detecta bien chew, pero no los otros eventos).

Es evidente que el árbol de decisión está “compensando” los errores del modelo de detección y clasificación de eventos.



# Procesamiento audio crudo

1.38	1.86	chewbite
4.16	5.12	chewbite
7.48	7.96	chewbite
8.6	9.08	chew
9.9	10.38	chewbite
10.92	11.44	chew
11.94	12.44	chewbite
16.56	17.1	bite
18.32	19.26	chewbite

6611	6652	Grazing
6751	6777	Grazing
6821	6832	Grazing
6840	6847	Grazing
7013	7015	Grazing
7017	7211	Grazing
7230	7271	Rumination
7274	7324	Rumination
7570	7678	Rumination
7757	7768	Rumination
7803	7806	Rumination

En el archivo de actividad alimentaria, notamos que la misma actividad aparece varias veces en rangos de tiempo aproximados. Estos casos deberían aparecer como un solo tramo unificado.

Sería necesario cambiar los parámetros de ventana del modelo clasificador de actividad o bien realizar un post-procesamiento (por ejemplo, un anti-rebote).

# Conclusiones

- Los modelos obtenidos tuvieron buena performance, lo cual implica que los preprocesamientos y las características seleccionadas son correctas.
- Modelos simples de inteligencia artificial pudieron resolver el problema, si el preprocesamiento era el correcto. Por esto, es fundamental el análisis y acondicionamiento de señales y la selección de características.
- Todos los pasos realizados son implementables en sistemas embebidos manteniendo un bajo consumo. Podemos construir un dispositivo de IoT con inteligencia artificial embebida para la detección y clasificación de eventos y actividades alimentarias de vacas.

# Propuestas de mejora

- Analizar otras características para mejorar la performance del modelo de clasificación de eventos para bite y chewbite.
- Mejorar la interacción entre el modelo de detección y el modelo de clasificación de eventos.
- Analizar y probar con cambios en los parámetros de ventana o realizar un post-procesamiento en el modelo de clasificación de actividad alimentaria, para obtener salidas más “continuas” o “suavizadas”.

# Referencias

[1] José O. Chelotti , Sebastián R. Vanrell, Diego H. Milone, Santiago A. Utsumi, Julio R. Galli, H. Leonardo Rufiner, Leonardo L. Giovanini. A real-time algorithm for acoustic monitoring of ingestive behavior of grazing cattle. Computers and Electronics in Agriculture (2016), 127, pp 64-75.

[2] José O. Chelotti , Sebastián R. Vanrell, Julio R. Galli, Leonardo L. Giovanini, H. Leonardo Rufiner. A pattern recognition approach for detecting and classifying jaw movements in grazing cattle. Computers and Electronics in Agriculture (2018), pp 83-91.

[3] José O. Chelotti, Sebastián R. Vanrell, Luciano Martinez Rau, Julio R. Galli, Alejandra M. Planisich, Santiago A. Utsumi, Diego H. Milone, Leonardo L. Giovanini, H. Leonardo Rufiner. An online method for estimating grazing and rumination bouts using acoustic signals in grazing cattle. Computers and Electronics in Agriculture (2020), 173, pp 105443.

